امیرمحمد پیرحسینلو 9531014
مهدی صفری

به نام خدا

برنامه‌نویسی چندهسته‌ای

دستور کار آزمایشگاه ۸

هدف از این آزمایش، انجام عملیات ریاضی Convolution به کمک gpu است.

عملیات Discrete convolution به صورت زیر تعریف می‌شود:

$$(f * g)[n] = \sum_{m=-\infty}^{\infty} f[m]g[n-m]$$

همان‌طور که از رابطه مشخص است این عملیات دو آرایه f و g را به عنوان ورودی گرفته و آرایه دیگری را به عنوان خروجی برمی‌گرداند. از آنجا که معمولا یکی از این دو آرایه ورودی دارای اندازه محدودتری است می‌توان به مساله به این شکل نگاه کرد که هر درایه در آرایه خروجی، جمع وزن‌دار تعدادی از همسایگان خودش در آرایه بزرگتر است و آرایه کوچکتر معمولا در نقش وزن‌ها ظاهر شده و اصطلاحا به آن convolution kernel (mask) گفته می‌شود.

به این ترتیب می‌توان در عمل به مساله به این شکل نگاه کرد که به ما یک آرایه ورودی و یک آرایه از وزن‌ها داده می‌شود و ما در خروجی به ازای هر خانه جمع وزن‌داری از همسایگانش را محاسبه می کنیم.

در مثال زیر نحوه انجام عملیات برای به دست آوردن یکی از درایه‌های ماتریس خروجی P به کمک آرایه ورودی N با اندازه ۷ و نیز آرایه convolution kernel به نام M با اندازه ۵ را مشاهده می‌کنید :

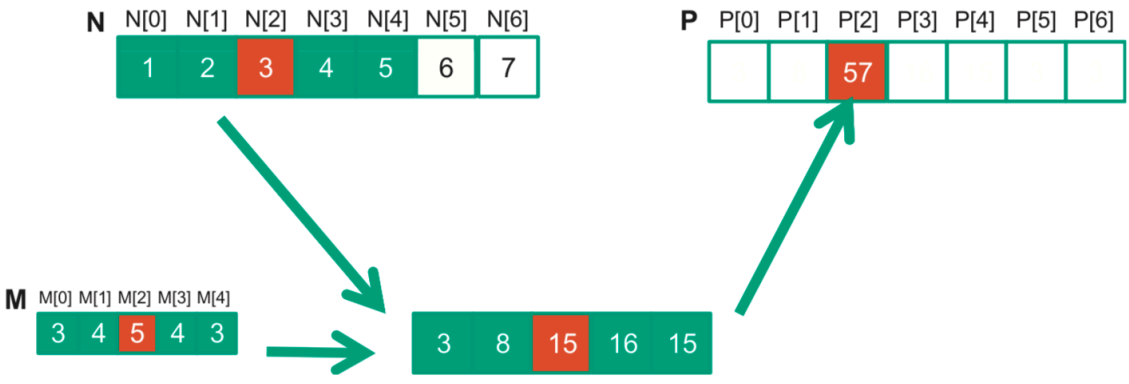

```
P[2] = N[0]*M[0] + N[1]*M[1] + N[2]*M[2] + N[3]*M[3] + N[4]*M[4]
     = 1*3 + 2*4 + 3*5 + 4*4 + 5*3
     = 57
```

هم چنین مطابق شکل زیر در صورتی که تعداد کافی المان در آرایه N وجود نداشت به تعداد لازم می توانیم از صفر استفاده نماییم :

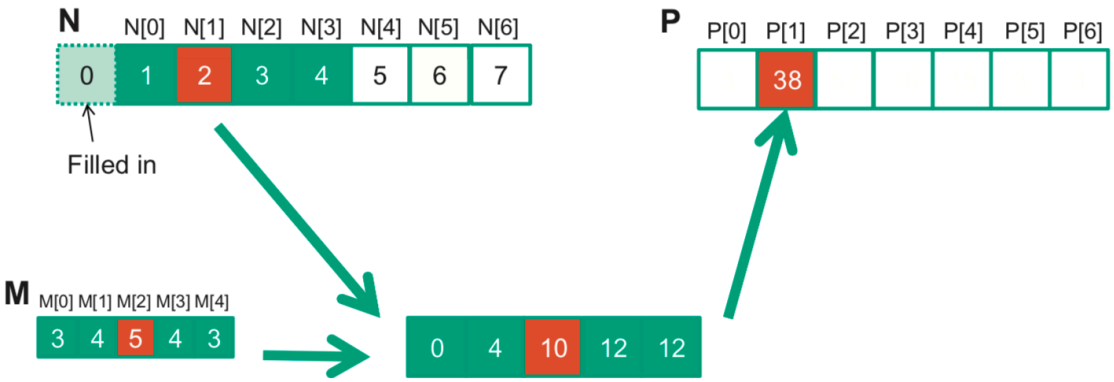


```
P[1] = 0 * M[0] + N[0]*M[1] + N[1]*M[2] + N[2]*M[3] + N[3]*M[4]
     = 0 * 3 + 1*4 + 2*5 + 3*4 + 4*3
     = 38
```

- این آرایه وزن‌ها (convolution kernel) در واقع همان تابع f(-x) در رابطه بالا می‌باشد. این موضوع را می توانید توجیه کنید؟

از آنجا که خانه اول کرنل طبق رابطه باید درخانه اخر خانه متناظر در پنجره ضرب می شد ولی اینگونه نیست، پس این همان تابع f(-x) است

- این عملیات کاربرد جدی در زمینه های کاری پردازش سیگنالی دارد. می‌توانید نمونه‌ای از کاربردهای آن را نام ببرید؟ پردازش تصویر - حذف نویز از نوار قلب

در این آزمایش، می‌خواهیم انجام این عمل در gpu را به کمک چند گام بهینه کنیم.

۱- گام اول: **پیاده سازی حالت ساده تابع کرنل**

در قطعه کد زیر می‌توانید پیاده سازی حالت ساده‌ای از کرنل را مشاهده نمایید.

```
__global__ void convolution_1 (float *N, float *M, float *P, int Mask_Width, int Width) {
  int i = blockIdx.x*blockDim.x + threadIdx.x;
  float Pvalue = 0;
  int N_start_point = i - (Mask_Width/2);
  for (int j = 0; j < Mask_Width; j++) {
    if (N_start_point + j >= 0 && N_start_point + j < Width) {
      Pvalue += N[N_start_point + j]*M[j];
    }
  }
  P[i] = Pvalue;
}
```

- توضیح دهید طبق الگوریتم چگونه خانه‌های آرایه P پر می شوند. هر نخ چه کاری انجام می‌دهد؟

هر نخ خانه متناظر با اندیس خود را در آرایه بزرگتر با پنجره مدنظر کانوالو کرده و نتیجه در آرایه خروجی در خانه متناظر با اندیس نخ نوشته می شود

- این کرنل را برای آرایه N با اندازه ۱۰۰ میلیون (400MB) و آرایه M با اندازه ۱۰ (40B) تست کرده و زمان آن را گزارش نمایید.

93.03 ms

۲- گام دوم: **استفاده از حافظه Constant**

همان طور که پیش از این نیز گفته شد M به عنوان convolution kernel معمولا دارای اندازه کوچک است و به ندرت از ۱۰ درایه بیشتر خواهد بود. هم‌چنین این آرایه به کرات توسط هر کدام از نخ‌ها استفاده می‌شود. این دو ویژگی باعث می‌شوند تا این آرایه کاندید خوبی برای حضور در حافظه Constant باشد.

نحوه پیاده سازی کد کرنل، در قطعه کد زیر مشخص است :

```
__global__ void convolution_2(float *N, float *P, int Mask_Width, int Width) {
  int i = blockIdx.x*blockDim.x + threadIdx.x;
  float Pvalue = 0;
  int N_start_point = i - (Mask_Width/2);
  for (int j = 0; j < Mask_Width; j++) {
    if (N_start_point + j >= 0 && N_start_point + j < Width) {
      Pvalue += N[N_start_point + j]*M[j];
    }
  }
  P[i] = Pvalue;
}
```

- با توجه به تصویر زیر که بیانگر یک شماتیک کلی از gpu و نحوه دسترسی آن به حافظه است می توانید توضیح بدهید چرا شرایط بالا، M را به گزینه خوبی برای حضور در حافظه Constant تبدیل می کند؟

سایز آرایه خیلی کوچک است. تنها عملیات خواندن روی آن اعمال می شود و دفعات زیادی مورد استفاده قرار میگیرد

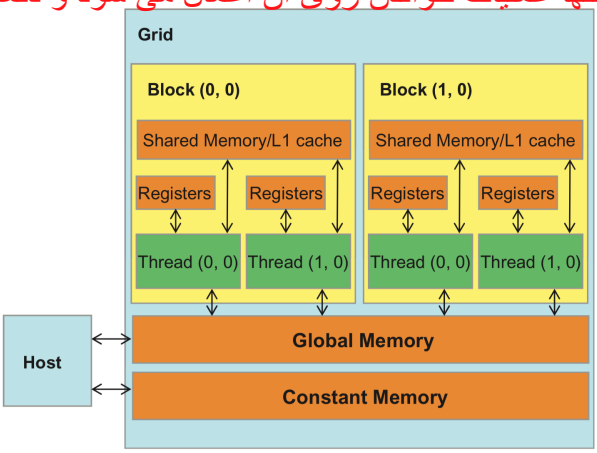

- به کمک deviceQuery اندازه constant memory را در gpuی که از آن استفاده می کنید گزارش کنید. 65KB

- به کمک Constant Memory و تابع cudaMemcpyToSymbol(dest, src, size) و توضیحات بالا کرنل و سایر بخش‌های موردنیاز کدتان را بازنویسی کرده و مجددا زمان را برای اندازه‌های گفته شده در تست قبلی محاسبه کنید.

52.57ms

speed up = 1.76

۳- گام سوم: **استفاده از حافظه shared**

در الگوریتم‌ها و سیستم‌های پردازش موازی، همواره یکی از مهم‌ترین گلوگاه‌های سیستم دسترسی به حافظه می‌باشد. به همین دلیل cacheها با سطوح متفاوتی در پردازنده‌ها طراحی شده‌اند تا بتوانند در شرایطی که دسترسی به حافظه ها محلی است به ما در بهینه‌کردن تعداد دسترسی‌ها به حافظه کمک کنند. در gpu به ازای هر block می‌توان مقداری از حافظه shared memory را برای استفاده محلی توسط نخ‌های آن block استفاده نمود. بنابراین همواره توجه داشته باشید که کنترل نحوه استفاده از این حافظه فقط بر عهده برنامه نویس است.

در این مساله دسترسی‌ها به حافظه N برای نخ‌های مجاور هر block، اشتراک دارد. طبق پیاده‌سازی قبلی، هر نخ به طور جداگانه به دنبال به دست آوردن تعدادی از خانه‌های حافظه N است که این حافظه‌ها توسط نخ‌های مجاور نیز از حافظه global در خواست می‌شوند. بنابراین با آوردن بخش های مورد نیاز از N به حافظه shared می‌توانیم بار زیادی را از دوش حافظه global برداریم.

برای مثال فرض کنید |N|=16 و |M|=5 است و ما می خواهیم به کمک blockهای ۴تایی این محاسبه را انجام دهیم. در شکل زیر می توانیم مشاهده کنیم هر کدام از این بلاک‌ها چه بخشی از حافظه را نیاز دارند.

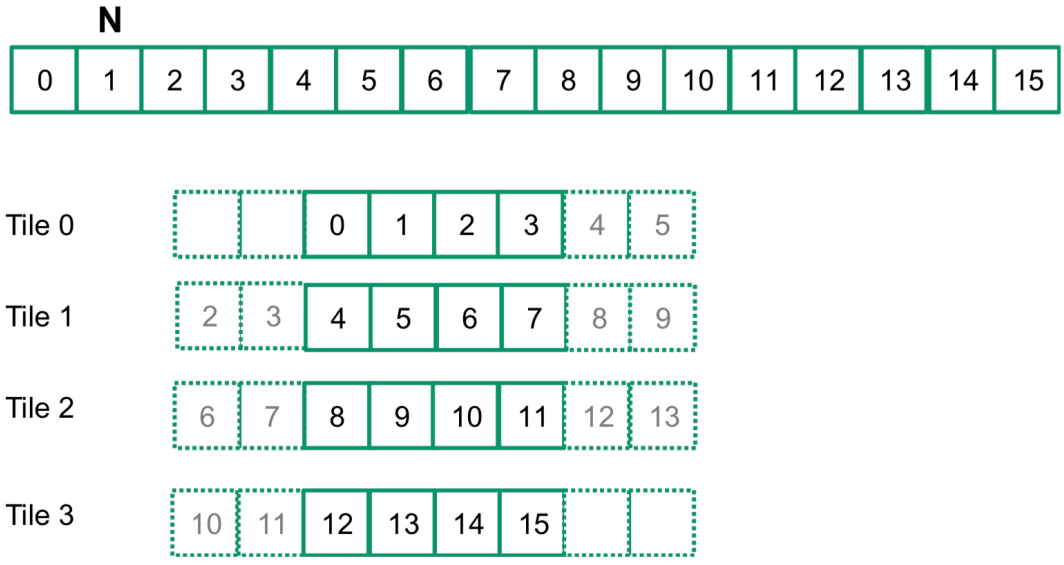

قطعه کد روبرو نحوه انجام این کار در کرنل را نشان می دهد :

```
__global__ void convolution_3(float *N, float *P, int Mask_Width, int Width) {
  int i = blockIdx.x*blockDim.x + threadIdx.x;
  __shared__ float N_ds[TILE_SIZE + MAX_MASK_WIDTH -1];
  int n = Mask_Width/2;

       //filling left side of N_ds
  int halo_index_left = (blockIdx.x - 1)*blockDim.x + threadIdx.x;
  if (threadIdx.x >= blockDim.x - n) {
    N_ds[threadIdx.x - (blockDim.x - n)] =
      (halo_index_left < 0) ? 0 : N[halo_index_left];
  }

       //filling main part of N_ds
  N_ds[n + threadIdx.x] = N[blockIdx.x*blockDim.x + threadIdx.x];

       //filling right side of N_ds
  int halo_index_right = (blockIdx.x + 1)*blockDim.x + threadIdx.x;
  if (threadIdx.x < n) {
    N_ds[n + blockDim.x + threadIdx.x] =
      (halo_index_right >= Width) ? 0 : N[halo_index_right];
  }

  __syncthreads();

       //calculating p ...
  float Pvalue = 0;
  for(int j = 0; j < Mask_Width; j++) {
    Pvalue += N_ds[threadIdx.x + j]*M[j];
  }

  P[i] = Pvalue;
}
```

- توضیح دهید چرا این روش تعداد دسترسی به حافظه را کمتر خواهد کرد؟

  از آنجا که خانه های مجاور را در حافظه مشترک هر بلاک آورده ایم دیگر نیاز نیست که نخ های مجاور سراغ حافظه اصلی بروند و کافی است در هر بلاک یک نخ سراغ حافظه اصلی برود

- در این کد از یک حافظه shared memory با نام N_ds برای هر block استفاده شده است. توجیه کنید چرا اندازه این حافظه TILE_SIZE + MAX_MASK_WIDTH -1 می باشد؟

  Tile_SIZE برابر اندازه بلاک است

  MAX_MASK_WIDTH - 1

  برای محاسبه کانولوشن خانه های ابتدایی و انتهایی آرایه ای که به صورت مشترک برای هر بلاک در نظر گرفته ایم باید تعدادی از خانه های ابتدایی حافظه مشترک بلاک بعدی و تعدادی از خانه های انتهایی حافظه مشترک بلاک قبلی را هم در حافظه مشترک بلاک فعلی قرار دهیم در این مثال این تعداد برابر 5 است به همین دلیل ماکزیمم سایز ماسک را در نظر گرفتیم تا به سایز آرایه مشترک اضافه کنیم

- نحوه پر شدن حافظه N_ds در این قطعه کد مشخص است. می توانید برای مثال ۱۶تایی بالا و به ازای Tile1 که در شکل زیر مجددا مشخص شده است بگویید هر کدام از خانه های Tile1 توسط نخ شماره چند پر می‌شوند؟

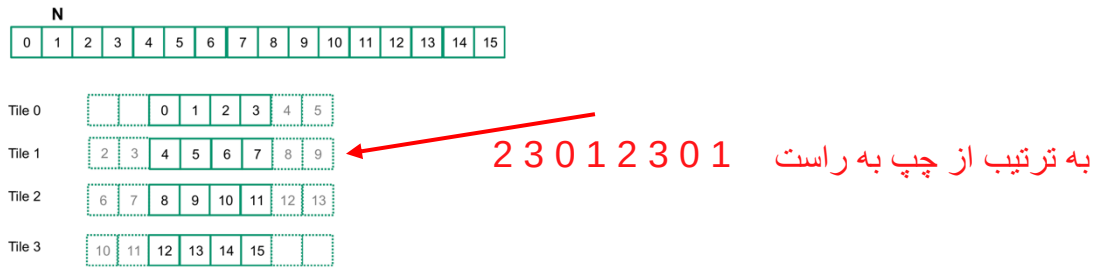

- به کمک قطعه کد داده شده مجددا اندازه گیری زمان را برای اندازه‌های گفته شده در تست‌های قبل تکرار کنید. 44.56 ms

speed up = 2.22